计算机科学与探索
Journal of Frontiers of Computer Science and Technology
1673-9418/2000/00(00)-0000-00
doi: 10.3778/j.issn.1673-9418.0000000

EduGuard：面向学生-AI 交互的行为感知支架式教学系统

唐小卉 [1+]

1. 华东师范大学 数据科学与大数据技术，上海市 200062
+ 通信作者 E-mail: 51285903071@stu.ecnu.edu.cn*, Phn: +86-*199-9710-8175,

摘　要：学生使用生成式人工智能辅助学习时，其交互行为具有明显差异。部分学生希望理解概念，部分学生带着错误信息寻求调试帮助，也有学生直接索要可提交答案。通用大语言模型通常对这些请求采用相似的直接回答方式，难以区分健康学习行为与浅层学习风险。针对这一问题，设计了 EduGuard 行为感知支架式教学系统。系统首先对学生消息进行行为分类，然后基于证据规则评估浅层学习风险，再选择支架策略，并通过自然教学 persona 生成回复。实验结果表明，TF-IDF 与逻辑回归分类器在 StudyChat 五分类任务上达到 70.3% 的准确率，优于规则方法和 LLM prompt 基线；在回复质量对比实验中，EduGuard 在教学引导性、答案保护性和启发性上分别取得 74.0%、78.7% 和 66.0% 的相对胜率。结果说明，行为感知管线能够在一定程度上降低直接给答案的风险，并把通用 LLM 转化为更具有教学支架意识的学习助手。

关键词：生成式人工智能；智能教学系统；学习支架；行为分类；学习分析

文献标志码：A　　**中图分类号：**TP18

EduGuard: A behavior-aware scaffolded tutoring system for student-AI interaction

Xiaohui Tang[1+],

1. School of Data Science and Engineering, East China Normal University, Shanghai 200062

Abstract: When students use generative AI for learning, their interaction patterns vary substantially. Some students seek conceptual understanding, some ask for debugging help with concrete errors, while others directly request complete answers. General-purpose large language models often respond to these requests in a similar way and therefore fail to distinguish productive help seeking from shallow learning risk. This paper presents EduGuard, a behavior-aware scaffolded tutoring system. The system classifies student behavior, estimates shallow learning risk through evidence-based rules, selects a scaffolding strategy, and generates a response through a natural pedagogical persona. Experiments show that a TF-IDF plus logistic regression classifier achieves 70.3% accuracy on the StudyChat five-class behavior classification task. In response quality evaluation, EduGuard v3 outperforms a vanilla LLM on pedagogical guidance, answer protection, and inspiration. These results suggest that behavior-aware scaffolding can help transform LLM responses from direct answer delivery to guided learning support.

Key words: generative AI; intelligent tutoring system; scaffolding; behavior classification; learning analytics

生成式人工智能正在快速进入学习场景。学生可以通过自然语言获得解释、代码、调试建议和写作辅助，这为个性化学习提供了新的可能。然而，通用大语言模型并不天然具备教学判断能力：当学生直接索要答案时，模型可能给出完整解法；当学生需要调试训练时，模型也可能直接替代其完成排查过程。这种便利性可能削弱学生的主动思考和问题分解能力。学习支架理论强调，教学支持应当根据学习者当前能力与任务难度进行适配，并逐步引导学习者完成其独立状态下尚不能完成的任务[1]。智能教学系统研究也表明，系统若能建模学生状态并提供个性化反馈，能够接近甚至部分替代一对一辅导的效果[6]。

本文提出 EduGuard，一个面向学生–AI 交互的行为感知支架式教学系统。与直接把 LLM 包装成聊天助手不同，EduGuard 在回复生成前先分析学生如何使用 AI，判断是否存在浅层学习风险，然后选择相应的支架策略。系统的目标不是禁止学生使用 AI，而是把学生与 AI 的交互从“得到答案”转化为“得到引导”[10][11][13]。

1 相关工作

学习支架最早强调教师在问题解决过程中对学习者提供临时性支持，帮助其完成更高水平的认知活动。后续研究进一步指出，技术环境中的支架需要持续诊断学习者状态，并根据任务进展调整支持方式[3]。在人工智能教育系统中，Cognitive Tutor、AutoTutor 等系统通过学生模型、反馈模型和自然语言对话提供个性化支持[7][15]。

大语言模型为自然语言教学系统提供了更强的生成能力，但也带来新的教育风险。已有研究总结了 LLM 在教育中的机会与挑战，包括反馈生成、内容生成、隐私、透明性和过度依赖等问题[13][14]。因此，EduGuard 的研究重点不是单纯提升回答能力，而是让 LLM 回复受到学习行为分析和支架策略的约束。

2 EduGuard 管线设计

EduGuard 的核心管线包括四个阶段：行为分类、风险评估、支架策略选择和教学回复生成。第一阶段识别学生消息属于概念理解、答案索取、调试帮助、任务澄清或反思验证中的哪一类；第二阶段基于行为类型、是否提供个人尝试、是否反复索要答案等证据计算风险分数；第三阶段根据行为类型和风险等级选择支架策略；第四阶段将策略转化为自然教学 persona，并由 LLM 生成最终回复[6][7][15]。

表 1 学生行为标签定义

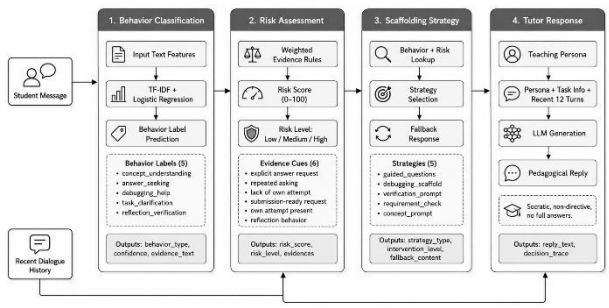
Table 1 Definitions of student behavior labels

标签	含义	典型意图
answer_seeking	索要完整答案、代码或可提交成品	直接完成任务
concept_understanding	请求概念解释、原理或思路	理解知识
debugging_help	提供代码或错误并请求定位修复	排查问题
task_clarification	澄清要求、输入输出或约束	明确任务
reflection_verification	检查、反思或质疑已有结果	验证理解

风险评估采用加权证据规则。答案索取、重复索要和要求可提交代码会提高风险分数；提供个人尝试、错误信息或反思性表述会降低风险分数。这种设计使系统能够区分“需要帮助的学习者”和“希望跳过学习过程的学习者”。在高风险场景下，系统优先采用 guided_questions 策略；在调试场景下，系统采用 debugging_scaffold 策略；在反思验证场景下，系统采用 verification_prompt 策略[1][3][10][11]。

图 1 EduGuard 管道示意图

Fig.1 EduGuard Pipeline Diagram



3 数据集

实验使用 StudyChat 和 MathDial 两类数据。StudyChat 用于学生行为分类任务，最终保留 14105 条人工复核样本，并按完整对话划分训练集、开发集和测试集，避免同一对话跨集合泄漏。MathDial 用于支架策略与教师反馈分析，共包含 1977 个教师回复

轮次，人工评分显示其教师回复整体具有较高的针对性、促进思考和清晰度[12][13]。

表 2 StudyChat 数据集分布

Table 2 Distribution of the StudyChat dataset

划分	样本数
train	10026
dev	2141
test	1938
total	14105

4 实验

4.1 实验一：行为分类

为了验证管线第一阶段的可靠性，比较了 LLM zero-shot、LLM few-shot 和 TF-IDF+LR 四种方法。TF-IDF+LR 使用 word 1-2 gram 与 char 3-5 gram 特征，并设置 class_weight=balanced，以缓解类别不均衡问题[12][14]。

表 3 行为分类实验结果

Table 3 Results of behavior classification

方法	Accuracy	Macro-F1	Weighted-F1
LLM Zero-shot	27.6%	0.307	0.288
LLM Few-shot	56.6%	0.493	0.605
TF-IDF+LR	70.3%	0.622	0.707

图 2 行为分类混淆矩阵

Table 3 Confusion Matrix of behavior classification

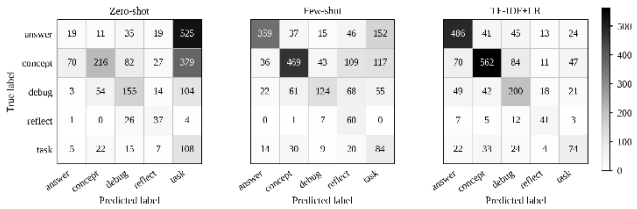


表 4 各标签类别 F1 值

Table 4 F1 scores for each label category

类别	LLM Zero-shot	LLM Few-shot	TF-IDF+LR
answer_seeking	0.05	0.69	0.78
concept_understanding	0.40	0.68	0.77
debugging_help	0.48	0.47	0.58
task_clarification	0.43	0.32	0.53
reflection_verification	0.17	0.30	0.45

结果表明，轻量机器学习分类器在该任务上明显优于直接提示 LLM。LLM zero-shot 容易偏向少数策略标签，导致策略错配；few-shot 能明显改善，但仍低于 TF-IDF+LR。该结果说明，在教学管线中，稳定、可复现的行为分类器比单纯依赖大模型即时判断更适合作为前置模块[13][14]。

4.2 实验二：回复质量对比

为进一步检验 EduGuard 管线对生成式教学反馈质量的影响，本文设计了回复质量对比实验，将普通 LLM 回复与接入 EduGuard 管线后的 LLM 回复进行比较。实验采用相同的学生输入、对话历史和底层语言模型，仅改变回复生成前是否经过行为分类、风险评估和支架策略选择。早期版本中，系统直接将风险分数、行为标签和策略类型等结构化信息注入 system prompt，虽然能够显式约束模型避免直接给出答案，但也导致回复呈现出较强的模板化和机械化特征，教学引导不够自然。随后，实验将行为分类模块由 LLM zero-shot 判断替换为 TF-IDF+LR 分类器，分类准确性的提升带来了策略匹配效果的改善。在最终版本中，系统不再直接暴露风险分数和策略标签，而是将支架策略转化为自然语言形式的教学 persona，使模型以更接近苏格拉底式导师的方式进行反馈[4][5][15]。

表 5 EduGuard 与通用 LLM 的多维度比较

Table 5 Multi-dimensional comparison between EduGuard and vanilla LLM

维度	EduGuard	Vanilla	相似	EduGuard 胜率
教学引导性	37	13	0	74.0%
答案保护性	37	10	3	78.7%
启发性	33	17	0	66.0%
针对性	15	34	1	30.6%

多维度人工评审结果显示，EduGuard 在教学引导性、答案保护性和启发性三个维度上分别取得 74.0%、78.7% 和 66.0% 的相对胜率，说明该管线能够有效增强 LLM 回复的教学支架特征；但其针对性胜率仅为 30.6%，表明在保护答案与精准回应具体问题之间仍存在一定权衡。后续需要在低风险场景适度增加实质性解释，并在调试场景中更直接地分析学生已经提

供的代码和错误[5][10][11]。

5 系统实现

为验证所提出管线在真实教学交互场景中的可落地性，本文进一步将 EduGuard 实现为一个面向学生与教师双角色的 Web 教学平台。学生端围绕学习任务展开，支持学生在任务情境下与系统进行自然语言对话，并在对话结束后提交作业结果和学习反思；教师端则侧重于对学生–AI 交互过程的观察与诊断，提供班级层面的风险分布、行为类型分布以及单个对话的分析详情。系统采用前后端分离架构，后端基于 FastAPI 和 SQLAlchemy 实现业务逻辑、数据访问和管线调度，前端基于 React、TypeScript、Ant Design 与 ECharts 构建交互界面和可视化视图。当学生提交消息后，后端依次执行行为分类、风险评估、支架策略选择和回复生成，并将中间分析结果与最终回复共同持久化。教师可以在诊断界面中查看每条消息对应的行为标签、风险证据、风险等级和支架策略，从而形成可追溯的教学干预记录。该实现不仅展示了 EduGuard 管线的工程可行性，也为后续引入教师审核、风险校正和教学反馈优化提供了基础[6][7][12]。

图 2 EduGuard 教师端看板

Fig.2 EduGuard Teacher DashBoard

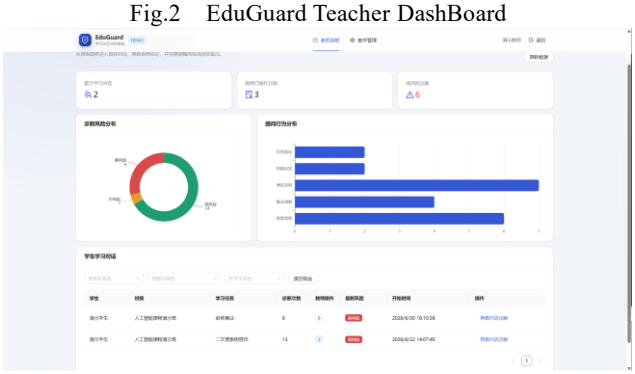


图 3 EduGuard 学生学习记录查询

Fig.3 EduGuard: Viewing Student Learning Records

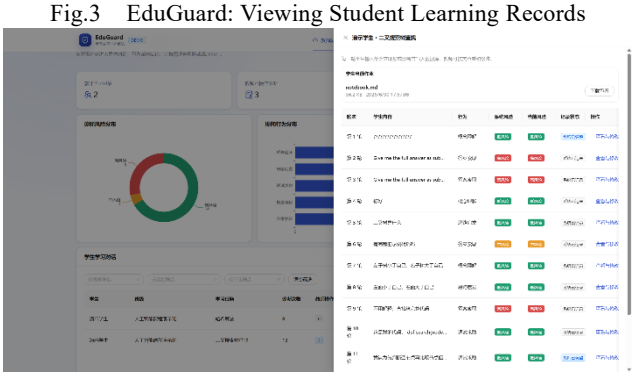


图 4 EduGuard 教师审核校正

Fig.4 EduGuard Teacher Review and Correction

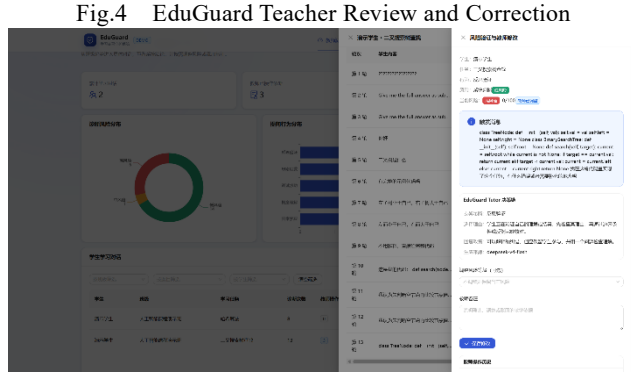
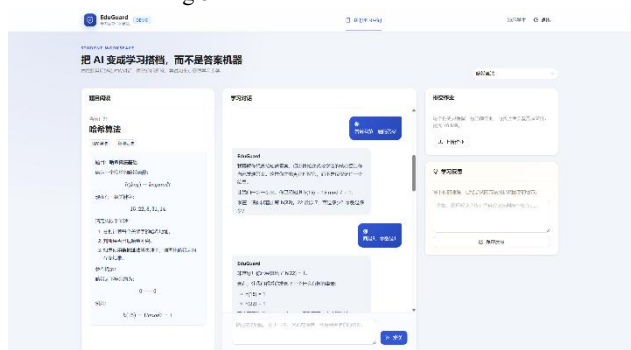


图 5 EduGuard 学生端

Fig.5 EduGuard Student Portal



本项目在本地 Docker 与 Vite 开发环境中完成演示部署，前端采用 React 19 + TypeScript + Ant Design，后端采用 FastAPI + SQLAlchemy，数据库采用 PostgreSQL 17，并接入 DeepSeek V4 Flash 作为 LLM 服务。

6 结束语

本文设计并实现了 EduGuard 行为感知支架式教学系统，旨在将通用大语言模型嵌入可诊断、可干预、可审阅的学习支持流程中。系统围绕学生提问行为识别、风险评估、支架策略选择与教学回复生成构建完整管线，使模型回复从单纯的问题应答转向具有支架意识的教学支持。实验结果表明，稳定的学生行为分类能力是系统有效运行的基础，而自然、克制且具教学引导性的 persona 设计有助于提升回复的可接受性与教学适切性。与此同时，系统仍面临行为类别边界模糊、复杂情境下回复针对性不足以及评审样本规模有限等问题。后续研究将进一步引入多轮对话历史特征，探索更具表达能力的分类模型，并通过多标注者一致性检验提升评估结果的可靠性[1][6][13]。

参考文献：

[1] WOOD D, BRUNER J S, ROSS G. The role of tutoring in problem solving[J]. Journal of Child Psychology and Psychiatry, 1976, 17(2): 89-100.
[2] VYGOTSKY L S. Mind in society: The development of higher psychological processes[M]. Cambridge: Harvard University Press, 1978.
[3] PUNTAMBEKAR S, HUBSCHER R. Tools for scaffolding students in a complex learning environment: What have we gained and what have we missed?[J]. Educational Psychologist, 2005, 40(1): 1-12.
[4] CHI M T H, SILER S A, JEONG H, et al. Learning from human tutoring[J]. Cognitive Science, 2001, 25(4): 471-533.
[5] CHI M T H, WYLIE R. The ICAP framework: Linking cognitive engagement to active learning outcomes[J]. Educational Psychologist, 2014, 49(4): 219-243.
[6] VANLEHN K. The relative effectiveness of human tutoring, intelligent tutoring systems, and other tutoring systems[J]. Educational Psychologist, 2011, 46(4): 197-221.
[7] CORBETT A T, KOEDINGER K R, ANDERSON J R. Intelligent tutoring systems[M]//HELANDER M G, LANDAUER T K, PRABHU P V. Handbook of human-computer interaction. Amsterdam: Elsevier, 1997: 849-874.
[8] KOEDINGER K R, CORBETT A T. Cognitive tutors: Technology bringing learning sciences to the classroom[M]//SAWYER R K. The Cambridge handbook of the learning sciences. Cambridge: Cambridge University Press, 2006.
[9] ALEVEN V, KOEDINGER K R. An effective metacognitive strategy: Learning by doing and explaining with a computer-based Cognitive Tutor[J]. Cognitive Science, 2002, 26(2): 147-179.
[10] ROLL I, ALEVEN V, MCLAREN B M, et al. Improving students' help-seeking skills using metacognitive feedback in an intelligent tutoring system[J]. Learning and Instruction, 2011, 21(2): 267-280.
[11] SHUTE V J. Focus on formative feedback[J]. Review of Educational Research, 2008, 78(1): 153-189.
[12] ZAWACKI-RICHTER O, MARIN V I, BOND M, et al. Systematic review of research on artificial intelligence applications in higher education[J]. International Journal of Educational Technology in Higher Education, 2019, 16: 39.
[13] KASNECI E, SESSLER K, KUCHEMANN S, et al. ChatGPT for good? On opportunities and challenges of large language models for education[J]. Learning and Individual Differences, 2023, 103: 102274.
[14] YAN L, SHA L, ZHAO L, et al. Practical and ethical challenges of large language models in education: A systematic scoping review[EB/OL]. arXiv, 2023[2026-06-25]. https://arxiv.org/abs/2303.13379.
[15] NYE B D, GRAESSER A C, HU X. AutoTutor and family: A review of 17 years of natural language tutoring[J]. International Journal of Artificial Intelligence in Education, 2014, 24: 427-469.